HackApertus OST Track 2A 技術レポート

スイス投票冊子に対する多言語 NLI と原文根拠の復元

(技術レポート)

チーム yasuhito (Yasuhito Takamiya)

2026 年 10 月 16 日 (リポジトリ master の最新コミット)

本稿は 2026-10-16 時点の提出版です。本文は 6 ページ以内で、参考文献はページ数に含めません。内容は公式テンプレート [8] の項目を含みます。本稿の数値はすべて、開発中に使った公開データでの測定値です。主催者の非公開 held-out データでの成績はわかっていません。

1 概要 (Summary)

本プロジェクトは HackApertus OST Track 2A[10] に取り組みます。入力はスイス連邦の投票冊子 (PDF) または短い参照文と、独語、仏語、伊語のいずれかで書かれた主張 (claim) です。システムは主張が原文から導けるか (0=entailment)、情報が足りないか (1=neutral)、原文と矛盾するか (2=contradiction) を判定し、判定の根拠となる原文を返します。

モデルは Apertus v1.5 の 70B と 8B です [17, 18, 19]。設計の中心は、モデルに引用文を書かせないことです。スクリプトが PDF をページ単位で抽出し、対象の投票案件のページを選び、原文の区間に ID を付けます。モデルは 1 件につき 1 回のネイティブの tool call でラベルと ID だけを返し、スクリプトが ID から原文とページ番号を復元します。冊子を読む Task A は 70B、参照文だけの Task B は 8B が答えます。Task A では、案件のページを 200 から 700 文字の段落に分け、主張に近い上位 8 段落とその隣接段落だけを渡します。段落の順位は、8B による主張の翻訳に対する BM25 と、ローカルの多言語埋め込みを融合し、主張の書き出しが示す冊子の節の段落を優先して決めます。やり直しても根拠を示せない非中立の回答は、案件の全ページで 1 回だけ答え直します。

2026-10-16 の朝、旧版 (v5) のページ選択が、正解根拠のあるページの 36% をモデルに渡していなかったことがわかりました。選択を冊子の見出しに基づく方式に直し、根拠の補完を加えた新版 (70B 親と 8B 子の 2 段構成) は、開発用 60 問 (DEV60)、公開 60 問 (PUBLIC60)、確認用 60 問のすべてで Task A の macro-F1 と根拠の一致率が v5 を上回りました。その後、新版の 420 件では 70B 親の最終回答が 8B 子の推奨とすべて一致していたことがわかり、子をなくして 1 回の呼び出しで答える構成 (R) に移りました (12:40 JST)。さらに、R に段落単位の文脈、節の優先、全ページでの再実行を加えた構成が、2026-10-16 18:00 JST 時点の本番構成です。提出用の実行系での 3 つの問題集の平均は、R に全ページを渡した場合と比べて、Task A F1 が 0.881 から 0.910、Hit@5 が 0.746 から 0.808 に上がり、トークンは 10,939 から 7,137/件、時間は 3.7 から 4.0 秒/件でした。

2 課題と評価 (Task and evaluation)

Task A(Document) は冊子 PDF 全体と投票案件名 (vote) を、Task B(Reference) は短い参照文を受け取り、JSONL で 1 件につき 1 行を返します。公式の Solution API Guide[9] によると、Task A で entailment または contradiction と答える場合は、原文言語の逐語引用を物理ページ番号 (1 始まり) 付きで 1 件以上返し、先頭 5 件 (各約 5,000 文字以内) が採点されます。Task B の根拠は任意で採点されず、返す場合のページは `null` です。

公式の評価は非公開 held-out での 3 クラス macro-F1 で、根拠の正確さ、トークン数、ケースあたりの時間も見ます [10, 9]。本稿では主催者の評価スクリプト (根拠の照合は rapidfuzz[3] の部分一致) をローカルで実行し、Task A と B の macro-F1、Hit@5(Task A で正解根拠のある問題のうち、先頭 5 件の根拠に正解箇所が含まれた割合)、1 件あたりのトークン数と時間、形式失敗 (既定回答に退避した件数) を比べます。データは公開データセット [14] の train split だけです。DEV60、PUBLIC60、確認用 60 問 (30 行を Task A と B の両方の形式で使用) はどれもここから選んだ 60 問で、すべて開発中に使ったため、本稿の数値は未知データでの性能の推定値ではありません。

3 システム構成 (Architecture)

図 1 に処理の流れを示します。

■PDF 抽出とページ選択 pypdf[2] で PDF をページごとにテキスト化します。ページ番号は PDF の物理ページです。Task A では `document_selection.py` の `vote_pages` が案件のページを選びます。連邦の冊子は、各見開きの先頭ページに `Erste Vorlage`、`Premier objet`、`Primo oggetto` のような序数の見出しを印刷しています。見出しが 1 つだけ現れるページをその案件のページとし、見出しのないページは直前の見出しページに属するとみなします。表紙や目次のように全案件の見出しが並ぶページは、どの案件にも割り当てません。案件名とページ冒頭の語の重なりで序数を決め、一致度が 0.45 に届かない場合と、見出しのない冊子 (単一案件など) では全ページを渡します。選ばなかったページは空文字列に置き換えるので、ページ番号は物理ページのまま保たれ、渡していないページは根拠として返せません。

■段落の絞り込み (Task A) 選んだページを、空行と文の境界で 200 から 700 文字を目安とする段落に分けます (`document_selection.py` の `paragraphs`)。段落はページ本文の連続した部分文字列で、単語の途中では切りません。主張の言語が冊子と異なる場合は、Apertus 8B[19] が主張を冊子の言語に訳します。短い呼び出しが 1 回増え、約 100 トークンをそのケースのトークンに含めます。段落の順位は、訳文に対する単語と文字 4-gram の BM25[15]、原文の主張の文字 4-gram の BM25、静的な多言語埋め込みのコサイン類似度を順位融合して決めます。さらに、主張の書き出しを 5 種類 (要約、委員会、連邦政府と議会、投票条文、可決されれば) に分け、冊子のページには節のラベル (冒頭の見開き、詳細、委員会の論点、連邦政府の論点、法律の条文) を付けます。ページの先頭には小さな目次があるので、先頭数行で最後に現れた見出しをそのページの節とし、ラベルのないページは直前のページのラベルを引き継ぎます。主張の種類に合う節の段落は、順位融合で先に並べます。公開データ 610 行では、残した段落に採点器の照合に通る正解段落が含まれる割合が 0.972 から 0.982 に上がり、文字数は 21% 減りました。埋め込みは model2vec の `potion-multilingual-128M` を int8 に量子化したもの (140 MB) で、numpy だけで CPU で動きます。重みはイメージに同梱し (節 7)、ローカルの埋め込みは大会の規則で許されています。上位 8 段落と、それぞれの同じページ内の前後の段落を残し、続き合う段落は 1 つの領域 (region) にまとめて、原文のまま渡します。

■source span と ID `source_spans.py` が各ページ (絞り込んだ場合は各領域) を最大 1200 文字の連続した区間に分けます。区切りは段落か文の境界を優先します。ID は物理ページ番号、開始と終了の文字オフセット、ページ本文の SHA-256 の先頭 12 桁からなります (例: `p0012-o0000000-e0001187-<hash>`)。Task B では参照文全体を 1 ページとして扱います。Task B の処理は以前と同じです。

■モデル呼び出し 提出用の実行系 (`track_2a/dev/format/runtime.py`、パイプライン R) は、Pi 1.1.0 の SDK[1] を通してネイティブの tool call を使います。1 件につき 1 つのモデルだけを呼び、渡すツールは `submit` だけです。子セッションはありません。入力に参照文があるケース (Task B) は `swiss-ai/Apertus-v1.5-8B`、冊子のケース (Task A) は `swiss-ai/Apertus-v1.5-70B` が答えます。以前の構成 (パイプライン C) では、70B 親が `subagent` ツール [4] で 8B 子を 1 回起動し、子の推奨を見て親が最終の `submit` を呼んでいました。

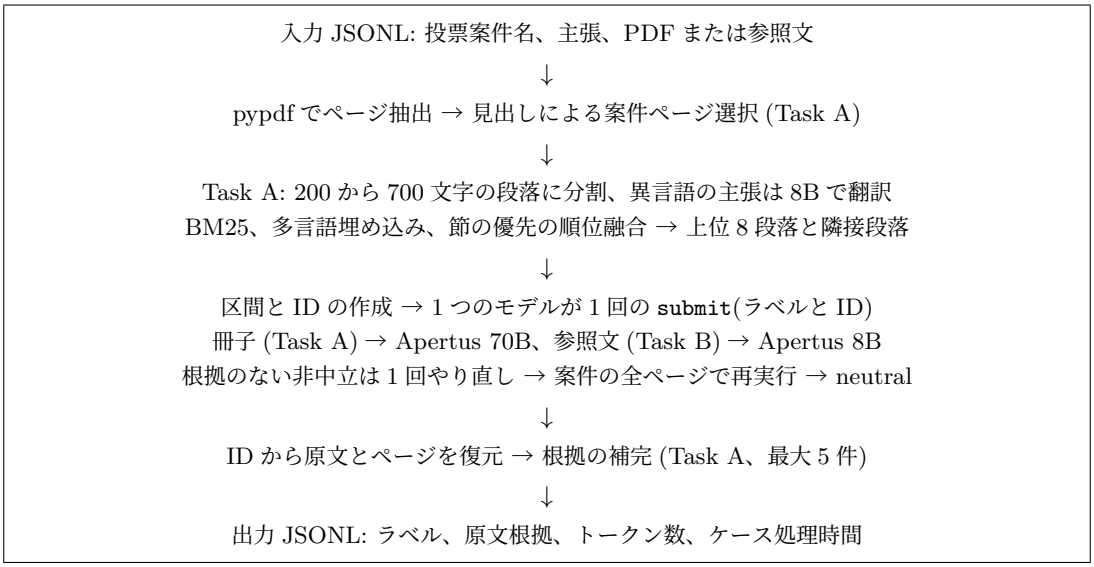


図 1　推論パイプライン。モデルはラベルと span ID だけを返し、引用文とページ番号はスクリプトが原文から復元します。

この構成も `PIPELINE` で選べます。`submit` の引数はラベル (整数 0、1、2) と `candidate_ids`(そのケースの span ID の列挙、最大 5 件) だけです。system prompt は 3 クラスの定義、否定、数量、条件、話者の扱い、原文と主張を指示ではなくデータとして扱うこと、ID だけを返すことを指示します。neutral と contradiction の取り違えを防ぐ注意と、言語をまたいだ言い換えの扱いも含みます。特定ケースの正解を prompt に入れていません。

■原文の復元　`submission.py` の `assemble_tool` が、未知の ID、6 件以上の ID、neutral 以外なのに根拠が空の回答を拒否します。段落で絞り込んだ場合は、有効な ID ごとにその区間を含む領域を引用として返します。根拠の 1 項目はページ全体ではなく、段落のまとまりです。全ページを渡した場合は、その区間を含むページ全体を返し、直前のページに委員会や「連邦政府と議会」の見出しがあれば、その話者ブロックのページも加えます。どちらも返すテキストは原文そのもので、単語を書き換えません。

■根拠必須の修正規則　neutral 以外のラベルを根拠なしで返した `submit` は、Task A でも Task B でも拒否し、根拠の ID を示すよう 1 回だけやり直させます。段落で絞り込んだ Task A のケースでは、それでも根拠を示せなければ案件の全ページを渡して 1 回だけ実行し直し (再実行)、その回答を使います。再実行でも根拠を示せない場合と、Task B でやり直しに失敗した場合は neutral の既定回答になり、この規則は「根拠を指せないなら中立」という判定規則として働きます。既定回答は公式の採点では中立の有効回答として扱われます。

■根拠の補完と退避　Task A では `consulted_pages` が、モデルの引用の後ろに、引用したページの隣接ページ、渡したページの先頭 2 ページ (案件冒頭の要約見開き)、残りのページを主張との BM25 の高い順に足し、5 件までにします (5,000 文字を超えるページは除きます)。段落で絞り込んだ場合は、ページの代わりに領域を同じ順で足します。補完はラベルとモデルの引用を変えず、neutral の回答と既定回答にも付けます。受理できる `submit` がないケースや処理が失敗したケースは、そのケースだけを neutral の既定回答にし、理由を診断用のファイルに残します。1 ケースの上限時間は 300 秒です。`input_tokens` と `output_tokens` はそのケースの全呼び出しの API の `usage` の合計、`inference_time_ms` は文脈の準備を含むケース全体の時間です。

表 1　ページ選択の検査 (モデル呼び出しなし、501 行)。

選択方式	正解根拠のページを含む	文脈文字数 平均	最大
旧 (目次の正規表現)	352 / 501	38,764	236,824
新 (見出し)	501 / 501	33,463	162,973

4　開発の経緯と診断 (Development history and diagnosis)

2026-10-14 に、system prompt の出力指示を `submit` の引数の形式に合わせた版 (v5) を採用しました (`docs/prompt-eval-log.md`)。v5 は DEV60 の 5 回平均で Task A F1 0.650、Task B F1 0.815、Hit@5 0.263 でした。10-15 の夜には、検証役や複数エージェントの研究 [5, 12, 6, 16] を動機に 8B の役を親に足す 3 つの構成を試しましたが、形式失敗が増え、根拠も改善しなかったので採用しませんでした。

10-16 の朝、モデルを呼ばずに DEV60 と PUBLIC60 で Task A の正解根拠がある 39 問を調べると、14 問 (36%) で正解根拠のページをモデルに渡していませんでした。旧方式は `im Detail` などの語で案件詳細節の開始を探していましたが、この語が目次ページに誤って一致し、参照文の出典になりやすい案件の要約見開き (In Kürze、En bref、In breve) が落ちていました。別に 3 問は、正解根拠が pypdf の抽出したどのページとも一致しませんでした。見出しによる方式に置き換え、確認用の 30 行を除く公開データで、正解根拠がページと一致する 501 行を検査しました (表 1、個別の正解行に合わせた調整はしていません)。

ページ選択だけを直しても DEV60 の Hit@5 は 0.263 のままで、モデルは正解ページを渡されても別のページを引用しました。関連箇所を入力に含めても使われるとは限らないという報告 [13, 11] と同じ傾向で、そこで根拠の補完を加えました。コミット 650de65 では重複 ID の統合、Task B の根拠の任意化、隣接ページの補完を加え、保存済みの回答の再採点で正解根拠を含む件数が 149 件中 89 件から 98 件に増えました。次節の表の新版の値は、この変更より前の版によるものです。

新版の 7 回の実行 (DEV60 を 3 回、PUBLIC60 を 1 回、確認用 60 問を 3 回、計 420 件) では、70B 親の最終回答が 420 件すべてで 8B 子の推奨と一致し、親の 2 回の呼び出しが全トークンの 63%、待ち時間の 65% を占めていました。そこで 1 つのモデルが 1 回の `submit` だけで答える構成として、70B だけの S と、Task A を 70B、Task B を 8B に振り分ける R を加えました。8B だけの 1 回呼び出しは DEV60 で Task A F1 0.714(テキストの JSON で答えさせると 0.361) で、冊子の問題では 70B に届かないため、Task A は 70B に残しました。Task B で根拠なしの非中立回答を受け入れていた間は、70B が話題違いの主張を根拠なしで矛盾と答えて Task B F1 が 0.693 まで落ちたので、コミット 8d5c7e6 で根拠必須の規則を Task B にも戻しました。

次に、案件のページから主張に関係する段落だけを渡す方式を試しました。公開データ 610 行で、残した段落のどれかが採点器の照合に通る割合は、訳文の BM25 だけで 0.970、埋め込みだけで 0.915、融合で 0.975(異言語の組で 0.968) で、渡す文字数は約 8,700 でした。しかし段落だけでは、Hit@5 は上がっても Task A F1 が下がりました (DEV60 で 0.833、PUBLIC60 で 0.857、確認用 60 問で 0.734)。矛盾を裏付ける箇所を引用できず既定回答に落ちる問題が増えたためで、段落を 12、16 に増やしても戻りませんでした (0.826、0.806)。そこで既定回答に落ちる問題だけを案件の全ページで答え直す再実行を加えると、開発用の実行系での 3 つの問題集の平均 Task A F1 は、全ページを渡す場合の 0.882 に対して 0.900 になりました。再実行した問題は 60 問中 11、8、6 問で、そのうち 6、4、3 問で根拠付きの回答を得ました。

主張の 96% は書き出しで出典を名乗り、要約を出典とする主張では、公開データの 96% で正解根拠が要約見開きにありました。これを使ったのが節の優先です。一方、勧告の向き (可決か否決か) を確かめさせる 1 文を system prompt に足すと、向きの誤り 5 件中 4 件は直りましたが、中立を矛盾とする誤りが 8 件増え、3 つの問題集の誤りは 180 問中 15 件から 17 件に増えたので、取り消しました。

表 2　v5、新版 (70B+8B)、R(全ページ)、R(段落、節の優先、再実行、採用) の比較。値は平均で、実行回数は DEV60、PUBLIC60、確認用 60 問の順に v5 が 5、5、3 回、新版が 3、1、3 回、R はどちらも各 1 回です。PUBLIC60 の v5 の時間は参照した資料に記録がありません。

問題集	構成	Task A F1	Task B F1	Hit@5	トークン/件	秒/件
DEV60	v5	0.650	0.815	0.263	28,232	6.3
	70B+8B	0.705	0.815	0.544	24,361	5.8
	R 全ページ	0.875	0.853	0.737	10,864	3.9
	R 段落 + 節 + 再実行	0.867	0.897	0.842	8,223	4.2
PUBLIC60	v5	0.701	0.917	0.30	30,382	記録なし
	70B+8B	0.869	0.931	0.65	28,964	6.5
	R 全ページ	0.967	1.000	0.750	11,000	3.8
	R 段落 + 節 + 再実行	1.000	0.967	0.750	7,314	4.1
確認用 60 問	v5	0.734	0.929	0.569	25,980	6.7
	70B+8B	0.797	0.929	0.625	28,843	6.8
	R 全ページ	0.802	0.904	0.750	10,954	3.5
	R 段落 + 節 + 再実行	0.863	0.903	0.833	5,874	3.7

5　結果 (Results)

表 2 に、v5、新版 (70B 親と 8B 子、コミット 76a0e6e)、全ページを渡す R、採用した段落、節の優先、再実行を使う R を比べます。確認用 60 問では、v5、新版の順に交互に各 3 回を実行し、すべて終わってから採点しました。R の 2 列は、提出用の実行系 (`runtime.py`) で各問題集を 1 回ずつ実行し、公式の採点器で採点した値です。温度 0 でも同じ入力で実行ごとに数件の差が出るので、1 回どうしの差が 0.03 程度なら偶然の範囲と見ています。

■v5 と新版　DEV60 では 3 回とも新版の Task A F1 が v5 を上回り (0.690 から 0.728)、確認用 60 問では v5 が送信上限の 240,000 バイトを超えた 1 問を既定回答かつトークン 0 としているため、両版が処理した 59 問で比べると v5 が 26,420、新版が 26,692 トークン/件です。新版は事前登録の基準のうち Hit@5(v5 より 0.10 以上高い、実際は +0.056) とトークン (v5 以下、実際は +11%) を満たしませんでしたが、所有者はこの 2 つを大会の規則にない基準として大会の評価項目で比べ直し、新版を採用しました (`docs/confirmation-protocol-2026-10-16.md`)。

■新版と R　全ページを渡す R は 3 つの問題集すべてで新版より Task A F1 と Hit@5 が高く、トークンは半分以下ですが、確認用 60 問では Task A F1 の差 (0.797 と 0.802) が偶然の範囲で、Task B F1 は新版の 0.929 に対して 0.904 でした。70B だけの S も Task A F1 と Hit@5 で新版を上回りましたが、既定回答が多く (DEV60、PUBLIC60、確認用 60 問で 15、10、8 件)、Task B で話題違いを矛盾と答える傾向があるため、R を選びました (`docs/single-call-results-2026-10-16.md`)。

■全ページと段落 + 節 + 再実行　3 つの問題集の平均で、採用した構成は Task A F1 を 0.881 から 0.910、Hit@5 を 0.746 から 0.808 に上げ、トークンを 10,939 から 7,137/件に減らし、時間は翻訳と再実行の分だけ 3.7 から 4.0 秒/件に増えました。Task A F1 の上昇は PUBLIC60(0.967 から 1.000) と確認用 60 問 (0.802 から 0.863) によるもので、DEV60 では 0.875 から 0.867 でした。Task B は冊子を使わないので、Task B F1 の差 (平均 0.919 と 0.922) は実行ごとのぶれです。

6　限界と今後 (Limitations and next steps)

■評価の限界　すべての数値は開発中に使った公開データでの値で、60 問、1 回から 5 回の実行です。採用した構成は各問題集 1 回しか測っていません。公式の held-out での成績はわかりません。

■抽出の限界　前述の新版の 420 件のうち、Task A で根拠が採点される 149 件を調べると、26 件は正解の根拠文が pypdf の抽出テキストと一致しません。この種の不一致は、根拠を領域単位にしたことで大部分が解消したと考えています。引用がページ全体より短くなり、採点器の部分一致に通りやすくなるからです。ただし、この 26 件を個別に採点し直してはいません。テキストを抽出できない PDF は OCR を行わずエラーにします。見出しのない冊子では全ページを渡すので、入力が長くなります。

■再実行の費用と実行環境　再実行は、段落で根拠を示せなかった冊子の問題に呼び出しを 1 回足します。埋め込みの重みを同梱する Docker イメージは 2026-10-16 に build し、end-to-end で動作を確認しました (節 7)。

■残る分類誤り　最終構成の 3 問題集 (各 1 回、計 180 問) では、ラベルの誤りが 15 件残ります。うち 5 件は、連邦政府や議会が可決と否決のどちらを勧めているかの取り違えで、Task B でも起きます。system prompt に規則を足すと向きの誤りは減りましたが、別の誤りが増えたので、副作用なしに直す方法はまだ見つかっていません。

■根拠の性質　source ID は引用が原文のどこから来たかを保証しますが、引用が判定を支えるかどうかは保証しません [7]。段落の絞り込みと、補完で足したページや領域は検索で選んだもので、モデルの判断ではありません。

■今後　採用した構成を各問題集で複数回実行し、実行ごとのばらつきを見積もります。抽出が一致しなかった 26 件が領域単位の根拠で当たるかを確かめ、残るものについて pypdf 以外の PDF 抽出ライブラリを比べます。

7　再現方法 (Reproducibility)

提出物は Docker で動かします。公式の契約 [9] では、CPU のみの linux/amd64 イメージで、注入された `BASE_URL` と `API_KEY` をすべてのモデル呼び出しに使い (ホストの鍵は読みません)、実行時にダウンロードしないことが求められます。`Dockerfile.agent` は、Node 26.10.0 の段階で `package-lock.json` から Pi 1.1.0 と `@tintinweb/pi-subagents` を入れ、`python:3.11-slim-bookworm` に `track_2a/src` と実行系をコピーし、`model2vec==0.10.0` と埋め込みの重みを `docker build` のときに同梱します。入口は `runtime.py` で、既定は `PIPELINE=R`(`Dockerfile.agent` と `Makefile` の両方)、`CONTEXT_SELECTION=claim_paragraphs`、`CLAIM_SPANS=8` です。`ESCALATE_ON_FALLBACK=0` で再実行を止め、`CONTEXT_SELECTION=vote_pages` で案件の全ページを渡します。`PIPELINE=C` で 70B 親と 8B 子、`PIPELINE=S` で 70B だけの構成を選べます。R では `LLM_MODEL` を指定しても使いません。

```
make run INPUT_DIR=/path/to/input INPUT=/data/input.jsonl \
  OUTPUT_DIR=/path/to/new/output
```

出力ディレクトリには正規の JSONL のほか、`.diagnostics.jsonl` と `.evaluation.jsonl` を書きます。Docker イメージは 2026-10-16 に linux/amd64 で build し、`make run` で 6 問を通して公式の採点器で読めることを確認しました (イメージ 249 MB、埋め込みの重み 140 MB を同梱)。

開発用のハーネスでは、Pi 1.1.0 を `~/.cache/ost-pi-1.1.0` に置き、`PI_PACKAGE_ROOT` と `PI_SUBAGENTS_ROOT` でその場所を指定します。リポジトリは `https://github.com/yasuhito/hackapertus-ost` で、提出リビジョンは master の最新コミットです。デモは用意せず、上記の CLI で再現します。

ライセンス (License)

リポジトリのコードには Apache License 2.0 が付いています (リポジトリ直下の `LICENSE`)。本レポートのライセンスは CC-BY-4.0 とします。大会規約では、コードと重みは Apache-2.0、文書は CC-BY-4.0、提出データセットは CDLA-Permissive-2.0 での許諾が定められています。同梱した pypdf は、同梱のライセンスファイルの条件に従います。公開データセット [14] のカードには MIT と記載され、作成者は OST の AI Applications and Deployment Lab です。投票冊子 PDF の再配布権は別途確認が必要で、本レポートには同梱しません。

参考文献 (References)

[1] @earendil-works/pi-coding-agent 1.1.0. npm package; version pinned in track_2a/dev/format/package.json.

[2] pypdf 6.1.1. `https://pypi.org/project/pypdf/`. Version pinned in track_2a/requirements.txt.

[3] rapidfuzz 3.14.6. Imported by the official evaluator (evaluate.py, fuzz.partial_ratio); version from the evaluator's uv.lock.

[4] @tintinweb/pi-subagents 0.19.0. npm package; version pinned in track_2a/dev/format/package.json.

[5] Dhuliawala et al. Chain-of-Verification reduces hallucination in large language models. `https://arxiv.org/html/2309.11495v2`, 2023. arXiv:2309.11495v2, revised 2023-09-25.

[6] Du et al. Improving factuality and reasoning in language models through multiagent debate. `https://arxiv.org/html/2305.14325v1`, 2023. arXiv:2305.14325v1, 2023-05-23.

[7] Gao et al. Enabling large language models to generate text with citations. `https://arxiv.org/abs/2305.14627v2`, 2023. arXiv:2305.14627v2, revised 2023-10-31.

[8] Hack Apertus. Track 2a technical report template. `https://github.com/HackApertus/project-template/blob/main/track_2a/technical_report.md`. Public raw Markdown checked 2026-10-12; adjustable template linked by the archived OST challenge.

[9] Hack Apertus and OST. Solution api guide. `https://hackapertus.notion.site/ef5b4fec112a834da43101ede56300f5`, 2026. Archive: docs/rules/notion/solution-api-guide-ef5b4fec.md, fetched 2026-10-12.

[10] Hack Apertus and OST. Track 2a: Multilingual natural language inference over swiss official voting booklets. `https://hackapertus.notion.site/3deb4fec112a80258fd2ddc61616011d`, 2026. Archive: docs/rules/notion/Track-2A-OST-3deb4fec.md, fetched 2026-10-12.

[11] Hsieh et al. RULER. `https://arxiv.org/abs/2404.06654v3`, 2024. arXiv:2404.06654v3, revised 2024-08-06.

[12] Huang et al. Large language models cannot self-correct reasoning yet. `https://arxiv.org/html/2310.01798v2`, 2024. arXiv:2310.01798v2, revised 2024-03-14.

[13] Liu et al. Lost in the Middle. `https://arxiv.org/abs/2307.03172v3`, 2023. arXiv:2307.03172v3, revised 2023-11-20.

[14] OST AI Applications and Deployment Lab. MNLI over Swiss Voting Booklets. `https://huggingface.co/datasets/OSTswiss/MNLIoverSwissVotingBooklets`. Archive: docs/rules/repositories/OSTswiss-MNLIoverSwissVotingBooklets-README.md, fetched 2026-10-12; metadata license: MIT.

[15] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 2009.

[16] Smit et al. Should we be going MAD? A look at multi-agent debate strategies for LLMs. `https://arxiv.org/html/2311.17371v3`, 2024. arXiv:2311.17371v3, revised 2024-07-18.

[17] Swiss AI Initiative. Apertus: Democratizing Open and Compliant LLMs. `https://arxiv.org/abs/2509.14233`. Listed in docs/rules/notion/Resources-Tools-0e9b4fec.md; the archived listing does not name individual authors.

[18] Swiss AI Initiative. swiss-ai/Apertus-v1.5-70B. `https://huggingface.co/swiss-ai/Apertus-v1.5-70B`. Model card; URL listed in docs/rules/notion/Challenge-1B-Swiss-Voices-3d7b4fec.md; model name as used in track_2a/dev/cscs/cscs_dev54.py.

[19] Swiss AI Initiative. swiss-ai/Apertus-v1.5-8B. `https://huggingface.co/swiss-ai/Apertus-v1.5-8B`. Model card; URL listed in docs/rules/notion/Challenge-1B-Swiss-Voices-3d7b4fec.md; model name as used in track_2a/dev/cscs/cscs_dev54.py.